

C3 分类与生成之间复用前缀

独立请求设计（概念对照）



保留 KV 的引擎路径（已实现）



10/10 次组合调用保留相同 KV block IDs，复用 1,788–1,830 个前缀 tokens。

非时间比例图；仍有回调、调度和续写 prefill；C4 回退仍使用独立请求。